张跃柯 Yueke Zhang

计算机科学博士候选人 | 代码大模型后训练与可信软件工程系统

研究方向

- **可信软件工程系统**：围绕代码生成的可靠性与开源软件供应链安全，研究代码大模型后训练、结果验证和贡献来源追溯。利用执行结果、程序结构与人类注意力设计训练信号，通过 SFT、DPO 和 GRPO 改进代码生成、修复与理解；结合身份风险分析、作者识别和托管安全检查，帮助开发者判断代码及其来源是否可信，并探索智能体的权限控制。

教育背景

范德堡大学 Vanderbilt University | 2023 - 2027（预计）
计算机科学博士候选人 | 导师：Yu Huang | 美国田纳西州纳什维尔

西南大学 | 2019 - 2023
管理信息系统学士 | 中国重庆

实习与科研经历

IBM Research · Thomas J. Watson Research Center | 2026 年春季
研究实习生 | 美国纽约州 Yorktown Heights
- 参与 SCOPE 可靠代码生成项目，主要负责语义反馈模型的输入输出接口、反馈设计、训练与评测流程，以及代码修订过程的分析。

范德堡大学 Vanderbilt University | 2023 - 至今
研究助理 | 美国田纳西州纳什维尔
- 研究代码模型后训练、执行与验证反馈，以及开源软件的贡献来源和基础设施安全。评估代码的功能正确性、跨任务迁移能力，以及反馈对开发者的帮助。

论文发表

1. Unclaimed Territory: Analyzing Subdomain Takeover Risks in GitHub Pages
Yueke Zhang, Zihan Fang, Yuxin Hu, Kevin Leach, Yu Huang.
ICSE 2027 · CCF A 类 | 第一作者

2. ScanCoder: Leveraging Human Attention Patterns to Enhance LLMs for Code
Yueke Zhang, Yifan Zhang, Zihan Fang, Greg Trafton, Daniel Levin, Kevin Leach, Yu Huang.
FSE 2026 · CCF A 类 | 第一作者 | 论文

3. Understanding and Detecting GitHub Impersonation through Automated Authorship Attribution
Yueke Zhang, Yifan Zhang, Pamela Wisniewski, Fengwei Zhang, Kevin Leach, Yu Huang.
TOSEM 2026 · CCF A 类期刊 | 第一作者 | 论文

4. Who’s Pushing the Code? An Exploration of GitHub Impersonation
Yueke Zhang, Anda Liang, Xiaohan Wang, Pamela Wisniewski, Fengwei Zhang, Kevin Leach, Yu Huang.
ICSE 2025 · CCF A 类 | 第一作者 | 论文

5. Leveraging Evidence Theory to Improve Fault Localization: An Exploratory Study
Yueke Zhang, Kevin Leach, Yu Huang.
ESEM 2023 · CCF B 类 | 第一作者 | 论文

6. Stop the Retrieval Thrash: Brain-Guided Episodic Memory for Repository-Scale Coding Agents
Yueke Zhang, Zihan Fang, Kevin Leach.
HumanAISE @ FSE 2026 | 第一作者 | FSE Companion，2 页 Workshop 论文 | 论文

7. CodeACT-R: A Cognitive Simulation Framework for Human Attention in Code Reading
Yueke Zhang, Zihan Fang, Greg Trafton, Daniel Levin, Kevin Leach, Yu Huang.
ASE 2025 NIER | 第一作者 | NIER 短文 | 论文

8. Eye-Mulator: Improving Code Language Models by Mimicking Human Visual Attention
Yifan Zhang, Chen Huang, **Yueke Zhang**, Jiahao Zhang, Toby Jia-Jun Li, Collin McMillan, Kevin Leach, Yu Huang.
ACL 2026 · CCF A 类 | 合作作者（第三作者） | 论文

9. Contribution Patterns in Open Source Software for Social Good: Dynamics, Individuals, and Impact
Zihan Fang, **Yueke Zhang**, Thomas Zimmermann, Denae Ford, Yu Huang.
CSCW 2026 · CCF A 类 | 合作作者（第二作者） | 论文

10. VERITAS: Verifier-Guided Proof Search for Zero-Shot Formal Theorem Proving
Manish Acharya, Zhenyu Liao, **Yueke Zhang**, Kevin Leach, Yu Huang, Yifan Zhang.
AI4Math @ ICML 2026 | 合作作者（第三作者） | Workshop 论文 | 论文

代表项目

软件工程中的供应链安全

第一作者 | 三篇系列论文：ICSE 2025、TOSEM 2026、ICSE 2027

- 围绕开源软件供应链中的信任问题，依次研究**贡献者身份是否可信、代码来源如何核查、项目托管基础设施是否安全**，从风险分析推进到辅助检测，并将研究范围从代码贡献扩展到项目域名。
- **贡献身份风险 · ICSE 2025**：在 Who’s Pushing the Code? 中，结合 **17 名贡献者访谈与 1,250 万条提交记录**，分析 GitHub 身份冒用及提交署名可能误导身份判断的情形，揭示仅凭提交元数据判断贡献来源的局限。
- **代码来源核查 · TOSEM 2026**：在后续作者识别研究中，结合代码特征与提交上下文，构建自动化作者归属方法，为识别潜在身份冒用提供概率性线索，辅助人工核查代码来源。
- **托管与域名安全 · ICSE 2027**：在 Unclaimed Territory 中，结合仓库历史和 DNS、HTTP 检查，确认 **284 个存在接管风险的 GitHub Pages 子域名**；通过 **288 名参与者**的研究分析域名信任问题，说明项目域名失去控制可能带来的风险。

SCOPE | 用 SFT 与 GRPO 训练代码语义反馈模型

第一作者 | IBM Research 实习项目 | 2026 年预印本

- 将 DeepSeek-Prover-V2-7B 适配为代码语义反馈模型，输出需要满足的子目标、代码尚未实现的要求和鲁棒性检查项。使用 LiveCodeBench V1-V3 的任务，构建 528 条由教师模型生成的反馈与修订样本。
- 先对模型输出部分进行 SFT，再用 GRPO 优化反馈质量。奖励考虑语义一致性、反馈质量和修订后代码的测试表现。训练时冻结下游代码生成模型，并用 4-bit QLoRA 更新反馈模型。
- 在 LiveCodeBench V6 **上达到 39.4% pass@1**，在 BigCodeBench Hard **上达到 42.6%**；Reflexion 的对应结果为 36.6% 和 36.5%。在 V6 上，仅进行 SFT 的版本为 35.4%。

GraphAlignCoder | 将程序结构与证明结构用于代码模型训练

第一作者 | 2026 年预印本

- 将 Python 代码区域与 Lean 证明流程对齐，让同一模型学习代码生成、验证概念预测，以及各代码区域需要满足的正确性条件。采用 LoRA 微调 Qwen3.5-4B-Base，仅对输出 token 计算训练损失。
- 完成结构学习后，再用 514 条代码样本进行**纯代码 SFT**，将结构知识用于 Python 代码生成。推理时只需提供编程任务，无需输入程序图或证明图。
- 使用单次贪心解码，在 LiveCodeBench V6 **解决 50/175 个任务**，在 BigCodeBench Hard **解决 23/148 个任务**；CodeRL 分别为 38 和 16 个。在 BigCodeBench Full 上解决 363/1,140 个任务。

ScanCoder | 用认知仿真生成可扩展的代码训练信号

第一作者 | FSE 2026

- 通过 ACT-R 认知仿真，模拟程序员阅读代码时关注的位置和顺序。将这些信息转化为**与子词对齐的交叉熵损失权重**，训练时只对模型输出计算损失。
- 将从 C++ 阅读行为中获得的认知模式用于 Java 任务，在相同设置下评估 **1B 至 8B 参数**的代码模型。代码补全 CrystalBLEU 最高提高 **41.66 分**，代码摘要 BERTScore 最高提高 **21.93 分**。