张跃柯 Yueke Zhang

计算机科学博士候选人 | 代码大模型后训练与可信软件工程系统

研究方向

- **代码大模型后训练与对齐**：利用执行结果、程序结构和人类注意力设计训练信号，通过监督微调（SFT）、偏好优化（DPO）和强化学习（GRPO），提升代码生成、修复与理解能力。
- **可信软件工程系统**：研究如何将验证、来源追溯和权限控制融入软件开发流程，让开发者能够检查生成结果、判断代码贡献的来源，并控制智能体可以执行的操作。已有研究覆盖 GitHub 身份冒用、代码作者识别和子域名接管风险。

教育背景

范德堡大学 Vanderbilt University | 2023 - 2027（预计）
计算机科学博士候选人 | 导师：Yu Huang | 美国田纳西州纳什维尔

西南大学 | 2019 - 2023
管理信息系统学士 | 中国重庆

实习与科研经历

IBM Research · Thomas J. Watson Research Center | 2026 年春季
研究实习生 | 美国纽约州 Yorktown Heights

- 参与 SCOPE 可靠代码生成项目，主要负责语义反馈模型的输入输出接口、反馈设计、训练与评测流程，以及代码修订过程的分析。

范德堡大学 Vanderbilt University | 2023 - 至今
研究助理 | 美国田纳西州纳什维尔

- 研究代码模型后训练、执行与验证反馈，以及开源软件的贡献来源和基础设施安全。评估代码的功能正确性、跨任务迁移能力，以及反馈对开发者的帮助。

代表项目与后训练方法

SCOPE | 用 SFT 与 GRPO 训练代码语义反馈模型

第一作者 | IBM Research 实习项目 | 2026 年预印本

- 将 DeepSeek-Prover-V2-7B 适配为代码语义反馈模型，输出需要满足的子目标、代码尚未实现的要求和鲁棒性检查项。使用 LiveCodeBench V1-V3 的任务，构建 528 条由教师模型生成的反馈与修订样本。
- 先对模型输出部分进行 SFT，再用 GRPO 优化反馈质量。奖励考虑语义一致性、反馈质量和修订后代码的测试表现。训练时冻结下游代码生成模型，并用 4-bit QLoRA 更新反馈模型。
- 在 LiveCodeBench V6 上达到 39.4% pass@1，在 BigCodeBench Hard 上达到 42.6%；Reflexion 的对应结果为 36.6% 和 36.5%。在 V6 上，仅进行 SFT 的版本为 35.4%。

GraphAlignCoder | 将程序结构与证明结构用于代码模型训练

第一作者 | 2026 年预印本

- 将 Python 代码区域与 Lean 证明流程对齐，让同一模型学习代码生成、验证概念预测，以及各代码区域需要满足的正确性条件。采用 LoRA 微调 Qwen3.5-4B-Base，仅对输出 token 计算训练损失。
- 完成结构学习后，再用 514 条代码样本进行**纯代码 SFT**，将结构知识用于 Python 代码生成。推理时只需提供编程任务，无需输入程序图或证明图。
- 使用单次贪心解码，在 LiveCodeBench V6 解决 50/175 个任务，在 BigCodeBench Hard 解决 23/148 个任务；CodeRL 分别为 38 和 16 个。在 BigCodeBench Full 上解决 363/1,140 个任务。

代表项目与后训练方法（续）

DPO-f+ | 用开发者偏好改进代码修复反馈

合作作者（第三作者）| 预印本，2026 年修订

- 参与代码修复反馈的偏好对齐研究。结合代码执行检查和七项反馈评价指标，构建 **6,284 对偏好样本**。按原始提交划分数据集，使同一提交及其增强版本进入同一子集，降低数据泄漏风险。
- 采用 DPO、**冻结的辅助奖励模型和参考策略正则化**，通过 LoRA 微调 Qwen2.5-1.5B-Instruct 与 CodeLlama-7B-Instruct，并根据验证集表现选择模型。
- 在新手编程任务上，pass@1 相对基线和 DPO 分别提高 **5.71 和 3.30 个百分点**；SWE-bench Lite 问题解决率分别提高 4.67 和 1.67 个百分点。在有 200 名开发者参与的研究中，初学者在 71.5% 的比较中偏好该方法的反馈。

EyeMulator | 用人类阅读注意力指导 SFT 与 DPO

合作作者（第三作者）| ACL 2026

- 参与开发不依赖特定模型架构的注意力训练方法。将开发者眼动转化为代码 token 的重要性权重和阅读位置之间的转移概率，为没有眼动标注的代码生成模拟阅读轨迹。
- 结合**加权 SFT 与 token 级 DPO**，将 AST 中的 token 权重映射到模型子词，并进行全参数微调。在 StarCoder-1B、Llama-3.2-1B 和 DeepSeek-Coder-1.3B 上评估代码补全、翻译和摘要任务。
- StarCoder 的 Java 到 C# 翻译 CodeBLEU 从 **52.07 提升至 86.42（提高 34.35 分）**；DeepSeek-Coder 的代码摘要 BERTScore 从 **28.64 提升至 51.56（提高 22.92 分）**。无需修改模型架构。

ScanCoder | 用认知仿真生成可扩展的代码训练信号

第一作者 | FSE 2026

- 通过 ACT-R 认知仿真，模拟程序员阅读代码时关注的位置和顺序。将这些信息转化为**与子词对齐的交叉熵损失权重**，训练时只对模型输出计算损失。
- 将从 C++ 阅读行为中获得的认知模式用于 Java 任务，在相同设置下评估 **1B 至 8B 参数**的代码模型。代码补全 CrystalBLEU 最高提高 **41.66 分**，代码摘要 BERTScore 最高提高 **21.93 分**。

可信软件工程系统与开源安全

GitHub 贡献来源与托管安全

第一作者 | ICSE 2025、TOSEM 2026、ICSE 2027

- 在 GitHub 身份冒用研究中，结合 17 名贡献者访谈与 1,250 万条提交记录，分析提交署名何时可能误导身份判断。在后续作者识别研究中，结合代码特征和提交上下文，为人工核查提供线索。
- 在 Unclaimed Territory 中，将仓库历史与 DNS、HTTP 检查结合起来，确认 284 个存在接管风险的 GitHub Pages 子域名，并通过 288 名参与者的研究分析域名信任问题。

技术能力

模型后训练：SFT、DPO、GRPO、奖励设计、LoRA/QLoRA、token 级损失加权、合成训练数据与消融实验。
程序分析与验证：Lean、AST/程序图、静态分析、基于执行和测试结果的评测。
编程与框架：Python、Java、Shell、PyTorch、TensorFlow。
语言：中文（母语）、英语（流利）。

论文发表

1. Unclaimed Territory: Analyzing Subdomain Takeover Risks in GitHub Pages
Yueke Zhang, Zihan Fang, Yuxin Hu, Kevin Leach, Yu Huang.
ICSE 2027 · CCF A 类 | 第一作者

2. ScanCoder: Leveraging Human Attention Patterns to Enhance LLMs for Code
Yueke Zhang, Yifan Zhang, Zihan Fang, Greg Trafton, Daniel Levin, Kevin Leach, Yu Huang.
FSE 2026 · CCF A 类 | 第一作者 | 论文

3. Understanding and Detecting GitHub Impersonation through Automated Authorship Attribution
Yueke Zhang, Yifan Zhang, Pamela Wisniewski, Fengwei Zhang, Kevin Leach, Yu Huang.
TOSEM 2026 · CCF A 类期刊 | 第一作者 | 论文

4. Who's Pushing the Code? An Exploration of GitHub Impersonation
Yueke Zhang, Anda Liang, Xiaohan Wang, Pamela Wisniewski, Fengwei Zhang, Kevin Leach, Yu Huang.
ICSE 2025 · CCF A 类 | 第一作者 | 论文

5. Leveraging Evidence Theory to Improve Fault Localization: An Exploratory Study
Yueke Zhang, Kevin Leach, Yu Huang.
ESEM 2023 · CCF B 类 | 第一作者 | 论文

6. Stop the Retrieval Thrash: Brain-Guided Episodic Memory for Repository-Scale Coding Agents
Yueke Zhang, Zihan Fang, Kevin Leach.
HumanAISE @ FSE 2026 | 第一作者 | FSE Companion，2 页 Workshop 论文 | 论文

7. CodeACT-R: A Cognitive Simulation Framework for Human Attention in Code Reading
Yueke Zhang, Zihan Fang, Greg Trafton, Daniel Levin, Kevin Leach, Yu Huang.
ASE 2025 NIER | 第一作者 | NIER 短文 | 论文

8. Eye-Mulator: Improving Code Language Models by Mimicking Human Visual Attention
Yifan Zhang, Chen Huang, **Yueke Zhang**, Jiahao Zhang, Toby Jia-Jun Li, Collin McMillan, Kevin Leach, Yu Huang.
ACL 2026 · CCF A 类 | 合作作者（第三作者） | 论文

9. Contribution Patterns in Open Source Software for Social Good: Dynamics, Individuals, and Impact
Zihan Fang, **Yueke Zhang**, Thomas Zimmermann, Denae Ford, Yu Huang.
CSCW 2026 · CCF A 类 | 合作作者（第二作者） | 论文

10. VERITAS: Verifier-Guided Proof Search for Zero-Shot Formal Theorem Proving
Manish Acharya, Zhenyu Liao, **Yueke Zhang**, Kevin Leach, Yu Huang, Yifan Zhang.
AI4Math @ ICML 2026 | 合作作者（第三作者） | Workshop 论文 | 论文